

UNIVERSIDAD TORCUATO DI TELLA

Maestría en Econometría

Trabajo Práctico: Programación Estadística

Alumno: Augusto Anton Baragiotta

Fecha: Septiembre 2026

1. Introducción y Objetivo

El presente informe documenta el desarrollo de un modelo de clasificación de fraude transaccional a partir de un dataset público de Kaggle. Este dataset fue generado a partir de solicitudes de apertura reales de cuentas bancarias online. El mismo contiene 1.000.000 de observaciones, con una tasa de fraude de únicamente el 1,1 %, lo cual implica que es completamente desbalanceado, como se puede observar en la Figura 1.




Figura 1: Desbalance de datos

El objetivo es implementar un modelo, en este caso una regresión logística, que permita predecir la probabilidad de fraude de una cuenta determinada (alguna que no haya sido vista por el modelo) minimizando la cantidad de falsos positivos (de cuentas genuinas catalogadas como fraudulentas).

2. Análisis Exploratorio de Datos

2.1. Tratamiento de valores faltantes

Un hallazgo relevante del análisis exploratorio es que varias variables numéricas codifican la ausencia de dato mediante valores negativos (típicamente -1) en lugar de utilizar valores faltantes explícitos (NA). Esto afecta a las siguientes variables:




Figura 2: Valores faltantes

Se recodificaron estos valores como NA de forma explícita, antes de cualquier otro procesamiento. Esta recodificación se realizó sobre el dataset completo porque la técnica de binning con WoE utilizada en la etapa de modelado asigna a los valores faltantes su propio bin, permitiendo así que el modelo capture si el hecho de no informar un dato es en sí mismo una señal predictiva (algo que se perdería si se reemplazara el faltante por un valor estimado, como por ejemplo la tendencia central de la variable).

2.2. Selección de variables mediante Information Value (IV)

Para priorizar el análisis sobre las variables con mayor poder predictivo individual, se calculó el Information Value (IV) y se mantuvieron bajo análisis, haciendo uso de los criterios de la industria, aquellas variables con un $IV > 0.02$:

Cuadro 1: Information Value (IV) y descripción de las variables del dataset

Variable	Descripción	IV
housing_status	Situación habitacional (categórica anonimizada)	0.826
zip_count_4w	Solicitudes del mismo código postal en 4 semanas	0.550
device_os	Sistema operativo del dispositivo	0.520
credit_risk_score	Score interno de riesgo de la solicitud	0.472
current_address_months_count	Meses en el domicilio actual (-1 = faltante)	0.430
proposed_credit_limit	Límite de crédito propuesto	0.395
prev_address_months_count	Meses en el domicilio anterior (-1 = faltante)	0.367
customer_age	Edad del solicitante, en rangos por décadas	0.332
date_of_birth_distinct_emails_4w	Correos distintos con igual fecha de nacimiento (4 sem.)	0.257
income	Ingreso anual del solicitante, en deciles	0.251
bank_months_count	Antigüedad de cuenta previa, en meses (-1 = faltante)	0.245
keep_alive_session	Si mantuvo la sesión abierta (binaria)	0.232
bank_branch_count_8w	Solicitudes en la sucursal elegida (8 semanas)	0.226
employment_status	Situación laboral (categórica anonimizada)	0.183
has_other_cards	Si posee otras tarjetas de la entidad (binaria)	0.160
payment_type	Tipo de plan de pago (categórica anonimizada)	0.156
phone_home_valid	Validez del teléfono fijo (binaria)	0.125
device_distinct_emails_8w	Correos distintos desde el mismo dispositivo (8 sem.)	0.105
email_is_free	Si el dominio del correo es gratuito (binaria)	0.074
month	Mes de la solicitud (0 a 7)	0.030

2.3. Relación bivariada de las variables con el fraude

Para las variables de mayor IV se analizó la relación bivariada con la variable objetivo utilizando la propia tabla de bins generada por el proceso de WoE, que permite visualizar en un mismo gráfico la distribución de la variable (barras) y la tasa de fraude por bin (línea). A modo de ejemplo, las siguientes figuras () muestran este análisis para las variables de score de riesgo de credito y el sistema operativo de los dispositivos con los que dan el alta los usuarios:




Figura 3: Distribución de las variables `credit_risk_score` y `prev_address_months_count`.

Nótese que, a pesar de que la gran mayoría de las personas tiene un score bajo, la probabilidad de fraude está concentrado principalmente en aquellas personas con un score de riesgo de credito alto. Por otra parte, la imagen 3 permite observar que el 71,2% de las solicitudes no informa esta variable, la cual a su vez concentra el mayor porcentaje de fraude. Esto está en línea con lo que se comentaba antes de la necesidad de no eliminar ni sustituir los valores nulos.

3. Metodología

3.1. Partición de los datos

A diferencia del tratamiento convencional de únicamente dividir a los datos en train y test, en este caso teniendo en cuenta el desbalance de los datos se hace una partición estratificada. Esto es, el train se compone del 70 % de las altas genuinas como del 70 % de las altas fraudulentas. El test se diseña con la misma lógica.

3.2. Transformación utilizando Weight of Evidence (WoE)

Cada variable predictora fue transformada a su valor de Weight of Evidence, calculado exclusivamente con el conjunto de entrenamiento. Esta restricción es central para evitar fuga de información: los puntos de corte de los bins y sus valores de WoE se derivan de la distribución y de la tasa de fraude observada en los datos de entrenamiento, por lo que

utilizar información del conjunto de test para calcularlos permitiría que el modelo viera indirectamente los datos que luego se usarán para evaluarlo.

4. Resultados

Sobre el conjunto de datos de testing el modelo alcanzo un AUC-ROC del 0.877, lo cual implica que se obtuvo un resultado solido. Sin embargo, estos numeros deben observarse con mayor reserva. Al ser un conjunto de datos tan desbalanceado, es normal que la tasa de falsos positivos sea reducida (debido a la gran cantidad de verdaderos negativos). En la imagen 4 se puede observar la curva ROC para el conjunto de test




Figura 4: Curva ROC

Estos resultados implican que el modelo asigna un score mayor al caso de fraude en un 87,7% de las comparaciones. No obstante, por lo que se comentaba anteriormente suele ser preferible reportar la curva de precision-recall cuando se trabaja con bases de datos tan desbalanceadas




Figura 5: Curva Precision-Recall

El AUC-PR al ser mas sensible al desbalance de los datos ofrece una visión mas conservadora. En efecto, el AUC-PR es de 0.130. Dado que un clasificador aleatorio

tendria un AUC-PR de 0.011 (que es la tasa de fraude en el dataset) el resultado obtenido implica una mejora de 12 veces con respecto al azar.

4.1. Umbrales

Utilizando el convencional umbral de 0.5 se obtuvo una precision del 0.579 (lo cual implica que un 57.9% de las cuentas con una probabiidad de fraude mayor al 0.5 son efectivamente fraudulentas) pero con un pobrisimo recall del 0.007 (solo obtengo el 0.7 % de los fraudes con respecto al total con este umbral) capturando muy poco del fraude total, como puede verse en la siguiente imagen 6a:




Figura 6

Al calcular el umbral que maximiza el F1, se obtiene que dicho umbral es de 0.11. Con este umbral, si bien aumenta la cantidad de falsos positivos, también aumenta considerablemente la cantidad de fraude capturado (recall) que es lo que prioriza el F1, resultados mas balanceados.




Figura 7: Matriz de Confusión con Umbral optimo

5. Undersampling

Por ultimo se aplico la técnica de undersampling para verificar si las métricas experimentaban una mejora. Como se puede observar en el siguiente imagen, la mejora es mínima luego de aplicar esta técnica




Figura 8: Undersampling

Por lo tanto, los resultados no mejoran sustancialmente luego de calcular el modelo con una base de datos compuesta por la misma cantidad de altas genuinas como de fraudulentas.

6. Conclusiones

El modelo desarrollado logra una capacidad de discriminación razonable (AUC-ROC de 0,877) manteniendo la interpretabilidad, donde cada variable aporta de forma aditiva al score final de riesgo. El principal hallazgo del análisis exploratorio es que buena parte del poder predictivo de las variables de mayor IV proviene de patrones de ausencia de información (por ejemplo, no declarar una dirección anterior) más que de la magnitud de las variables numéricas en sí.

Entre las limitaciones del enfoque, se destaca que la regresión logística es un modelo aditivo que no captura interacciones entre variables de forma automática (a diferencia de modelos de árboles), lo cual probablemente explique parte de la brecha entre el desempeño obtenido y el reportado en la literatura para este mismo dataset con modelos no lineales. Esta limitación se asume como un trade-off deliberado entre desempeño e interpretabilidad.

En conclusión, el modelo logístico puede constituir una buena primera aproximación (un benchmark) para el estudio de la probabilidad de fraude en bases altamente desbalanceadas.